



PONTIFÍCIA UNIVERSIDADE CATÓLICA DE GOIÁS

Atividade Avaliativa:
PROPOSTA DO PROJETO INTEGRADOR IV – B

Rairon Braga, Victor Gabriel

Goiânia – 2026

DIAGNÓSTICO ORGANIZACIONAL E CONTEXTUALIZAÇÃO DO PROBLEMA

O Ministério da Educação (MEC) e as Secretarias Estaduais de Educação enfrentam, historicamente, o desafio complexo da evasão escolar no Ensino Médio. O abandono das salas de aula gera prejuízos sociais intangíveis e compromete o desenvolvimento econômico do país. O Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP) publica anualmente os microdados de rendimento escolar de todo o ecossistema de ensino nacional. No entanto, as Secretarias e órgãos de governança pública sofrem com o que a literatura de tecnologia classifica como "cegueira analítica pontual".

A raiz desse problema reside na infraestrutura de processamento de dados. Os microdados brutos do INEP são disponibilizados em arquivos planos de texto ou valores separados por vírgulas (CSV) massivos, contendo milhões de registros e esquemas de dados complexos. As organizações públicas parceiras tentam consumir essas planilhas por meio de ferramentas de escritório tradicionais baseadas em sistemas legados de armazenamento local (como o Microsoft Excel). Como resultado prático, os computadores das secretarias sofrem com travamentos de memória, truncamento de linhas e corrupção de tipos de dados.

Esse gargalo operacional gera um atraso analítico severo. Os relatórios tradicionais de evasão costumam ficar prontos meses após o encerramento do ano letivo. Sem um mecanismo ágil de processamento em tempo real, os gestores públicos perdem a janela de oportunidade para aplicar políticas de contenção, tornando-se incapazes de identificar de forma cirúrgica quais escolas e comunidades específicas exigem intervenção orçamentária imediata antes que o ciclo de abandono se consolide.

JUSTIFICATIVA ECONÔMICA E GERAÇÃO DE VALOR (ROI DE DADOS)

A transição de uma arquitetura baseada em planilhas locais para um pipeline distribuído em nuvem justifica-se financeiramente a partir da otimização do orçamento público e da eficiência de gestão de recursos, dividida em três pilares fundamentais:

- **Redução Drástica do Custo Operacional (Hora/Homem):** O esforço computacional e humano para higienizar e cruzar milhões de registros em sistemas legados consome semanas de trabalho de equipes inteiras de analistas públicos. Ao implementar a automação em Apache Spark, esse tempo de processamento é reduzido para minutos, reduzindo drasticamente o custo operacional de engenharia e permitindo que o corpo técnico foque em ações diretas de acolhimento estudantil.

- **Otimização do Custo-Aluno e Eficiência Orçamentária:** Cada estudante que desiste da escola representa um desperdício direto das verbas públicas empenhadas no custeio de infraestrutura, logística de transporte, distribuição de merenda e pagamento de salários docentes que passam a operar com salas ociosas. Mitigar a evasão a partir de dados precisos protege a eficiência e o Retorno sobre o Investimento (ROI) do orçamento destinado à educação básica.
- **Alocação Cirúrgica de Recursos Assistenciais:** Projetos de assistência social focados em distribuição uniforme de verbas pecam por dispersão de capital. O pipeline de Big Data gera valor econômico ao funcionar como um rastreador de anomalias severas. Ao mapear microrregiões específicas com taxas críticas de abandono, o governo consegue focar o envio de verbas carimbadas (bolsas permanência, apoio psicológico e reforço alimentar) diretamente para os pontos de crise, evitando o desperdício de fundos em áreas já consolidadas.

ARQUITETURA TÉCNICA E METODOLOGIA DO PIPELINE SPARK

Para o processamento escalável e seguro da massa de dados do INEP, foi desenvolvido um pipeline de dados baseado na **Arquitetura Medalhão** dentro da plataforma **Databricks**, utilizando o motor distribuído **Apache Spark (PySpark)**. A linha de montagem foi estruturada em três estágios lógicos para assegurar a integridade e precisão dos dados analíticos:

[Dados Brutos INEP] -> (Camada Bronze) -> (Camada Silver:
 Limpeza/Regex/Cast) -> (Camada Gold: BI).

Camada Bronze (Ingestão e Carga Inicial)

O arquivo bruto de rendimento escolar foi carregado no ambiente do Databricks sem transformações destrutivas. Para mitigar erros de inferência automática de esquemas que frequentemente corrompem a leitura de arquivos grandes, as colunas foram forçadas inicialmente como strings.

Camada Silver (Higienização, Regex e Padronização)

Esta camada concentrou as maiores complexidades técnicas do código, resolvendo anomalias de formatação que inviabilizavam cálculos matemáticos em ferramentas tradicionais:

- **Renomeação Técnica:** Colunas de códigos internos do INEP (ex: 3_CAT_MED) foram mapeadas e transformadas para nomenclaturas legíveis por negócios (Taxa_Evasao).

- **Tratamento de Strings e Nulos:** O Spark foi configurado para tratar caracteres especiais de omissão de dados (--) e textos nulos de sistema ('nan').
- **Tratamento de Tipagem Regional:** Utilizando funções nativas como `regexp_replace`, substituiu-se o padrão brasileiro de separação decimal por vírgulas (ex: 5,5) pelo padrão internacional por pontos (ex: 5.5).
- **Cast de Dados:** As taxas foram convertidas de texto para vetores numéricos de precisão flutuante (`FloatType`), habilitando operações matemáticas de agregação.

Camada Gold (Agregação de Negócios e Governança)


Com a base limpa e precisa na camada Silver, foram aplicadas funções de agrupamento (`groupBy`), cálculo de médias aritméticas estruturadas (`avg`), ordenações decrescentes (`orderBy`) e filtros seletivos restritos por estados e limites estatísticos (`limit(10)`), originando tabelas otimizadas prontas para consumo em ferramentas de Business Intelligence.

RESULTADOS OBTIDOS E INSIGHTS DE INTELIGÊNCIA DE NEGÓCIO

O Dashboard executivo desenvolvido na plataforma Databricks foi estruturado em três níveis analíticos complementares, permitindo uma investigação que parte do cenário macro nacional até o diagnóstico cirúrgico das unidades escolares mais críticas.

Visão Macro Nacional: Análise por Unidade da Federação (UF)

O primeiro nível de análise do pipeline consistiu em mapear a taxa média de evasão em nível nacional, agrupando os dados por estado para identificar as regiões geográficas de maior vulnerabilidade.




Análise dos Resultados e Justificativa de Negócio:

- **Acre na Liderança Crítica:** O processamento distribuído revelou uma anomalia estatística severa: o estado do **Acre (AC)** apresenta a pior situação do país, com uma taxa média de evasão alarmante de aproximadamente **10,8%**, destacando-se significativamente das demais unidades federativas.
- **Foco Estratégico:** Esse insight macro foi o fator determinante para a tomada de decisão no Business Case, direcionando o pipeline a realizar

um isolamento cirúrgico nos dados do Acre para entender as causas dessa taxa atípica.

Visão Macro Administrativa: Impacto por Rede de Ensino

O segundo cruzamento avaliou o comportamento do abandono escolar separando as instituições por suas dependências administrativas, isolando a responsabilidade de gestão.




Análise dos Resultados e Data Quality:

- **Gargalo nas Redes Públicas:** As redes **Municipal** e **Estadual** concentram os maiores índices de abandono mapeados pelo Spark, com médias de aproximadamente **5,5%** e **3,5%** respectivamente. A rede **Federal** demonstra estabilidade (cerca de **1,5%**) e a rede **Privada** opera no limite mínimo (abaixo de **0,5%**).
- **Evidência de Tratamento de Dados:** Vale destacar a precisão do pipeline na camada Silver, que higienizou a base eliminando registros corrompidos e strings inválidas ('nan'), garantindo que apenas as categorias administrativas reais fossem computadas, blindando o gráfico contra ruídos analíticos.

Visão Micro Localizada: Detalhamento de Anomalias no Estado do Acre (AC)

Após identificar o Acre como o ponto focal de crise no país e as redes públicas como os canais mais afetados, o pipeline executou um filtro microscópico para listar as 10 escolas em situação mais severa no estado.



Análise dos Resultados:

- **Cenário de Alerta Máximo:** O algoritmo isolou um cenário crítico onde **8 das 10 piores escolas do estado atingiram 100% de evasão** no Ensino Médio Regular.
- **Padrão Geodemográfico Detectado:** O Spark revelou que **90% das instituições desse ranking crítico são Escolas Indígenas** (comunidades Kaxinawa, Huni Kuin e Yawanawa), localizadas em áreas de floresta e fronteira nos municípios de **Tarauacá e Feijó**.
- **Retorno Estratégico (ROI):** Esse insight final consolida o Business Case, provando aos tomadores de decisão que as verbas assistenciais e políticas de permanência estudantil do Estado do Acre precisam ser aplicadas de forma imediata e exclusiva nas comunidades indígenas dessas coordenadas geográficas específicas.

EVIDÊNCIAS DE INTERAÇÃO E GOVERNANÇA DO PROJETO

O desenvolvimento deste projeto de Big Data seguiu estritamente o cronograma analítico e as diretrizes de governança estabelecidas pela coordenação da disciplina. O escopo da solução e os parâmetros das regras de negócio aplicadas no Apache Spark foram refinados e validados em conformidade com os seguintes marcos temporais e de evolução:

- **Março / 2026 – Alinhamento de Escopo e Definição Inicial:** Fase dedicada à escolha e validação da base de dados pública de rendimento escolar do INEP (ano-base 2024). Estabeleceu-se o recorte analítico focado exclusivamente no Ensino Médio Regular, estruturando o problema sob a ótica de eficiência na Governança Pública (MEC e Secretarias de Educação).
- **Abril / 2026 – Homologação da Arquitetura e Engenharia de Dados:** Etapa de desenvolvimento técnico voltada para a configuração do pipeline no ambiente Databricks utilizando a Arquitetura Medalhão (Camadas Bronze, Silver e Gold). Definição das regras de negócio para a higienização de registros corrompidos e nulos ('nan', --), além do tratamento de strings decimais via PySpark.
- **Maior / 2026 – Análise Descritiva e Extração de Insights:** Fase de processamento das agregações na Camada Gold do Spark. Realização dos cruzamentos macro por Unidade da Federação e por dependência administrativa, resultando no isolamento estatístico da liderança crítica de evasão no estado do Acre e na identificação do gargalo nas redes públicas de ensino.
- **Junho / 2026 – Encerramento da PoC e Homologação Final:** Consolidação do Dashboard executivo integrado na plataforma, validação final das regras de negócio aplicadas e fechamento da

documentação técnica da Prova de Conceito (PoC) para apresentação e entrega formal à banca avaliadora.

As interações serviram para balizar os limites do pipeline, definindo a filtragem exclusiva para o Ensino Médio Regular e validando as decisões técnicas de engenharia de dados — como o uso da Arquitetura Medalhão e a escolha de focar a análise descritiva na integridade dos dados e na descoberta de anomalias regionais severas, em vez de métricas de faturamento comercial que seriam incompatíveis com o cenário de gestão governamental.

CONCLUSÃO E EVOLUÇÃO PREDITIVA

O projeto demonstrou com sucesso a eficácia prática da união entre Engenharia de Big Data e Business Intelligence na esfera pública. O pipeline distribuído construído em Apache Spark provou ser plenamente capaz de extrair valor de volumes massivos de microdados brutos do INEP, gerando análises precisas, higienizadas e acionáveis em tempo recorde se comparado aos métodos legados de escritório.

Como proposta de evolução do produto de dados, os próximos passos compreendem a integração desta base limpa e estruturada (Camada Gold) a modelos de Machine Learning (SparkML / Scikit-Learn). O objetivo futuro é construir algoritmos preditivos que calculem o risco probabilístico de evasão de cada escola antes do encerramento do período letivo, permitindo uma atuação preventiva e automatizada por parte do Estado.

REFERÊNCIAS BIBLIOGRÁFICAS

- **INEP.** *Microdados do Censo da Educação Básica 2024*. Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira, 2024. Disponível em: <https://www.gov.br/inep>.
- **APACHE SPARK.** *Apache Spark PySpark API Documentation*. Apache Software Foundation, 2026. Disponível em: <https://spark.apache.org/docs/latest/api/python/>.
- **DATABRICKS.** *Databricks Cloud Documentation*. Databricks, 2026. Disponível em: <https://docs.databricks.com/>.